

# A multimodal dataset for reconstructing common marmoset body–environment interactions in a 3D digital-twin framework

Koki Iwata<sup>1</sup>, Takaaki Kaneko<sup>2</sup>, Catia Correia Caeiro<sup>3</sup>, Diego Thomas<sup>4</sup>, Daisuke Koketsu<sup>2</sup>, Atsushi Nambu<sup>2</sup>, Takako Miyabe-Nishiwaki<sup>5</sup>, Junichi Hata<sup>6</sup>, and Ken Nakae<sup>1</sup>

<sup>1</sup>Graduate School of Engineering, University of Fukui, Japan

<sup>2</sup>National Institute for Physiological Sciences, National Institutes of Natural Sciences, Japan

<sup>3</sup>Institute of Biology, Leipzig University, Germany

<sup>4</sup>Kyushu University, Japan

<sup>5</sup>Center for the Evolutionary Origins of Human Behavior, Kyoto University, Japan

<sup>6</sup>Center for Brain Science, RIKEN, Japan

## Abstract

コモンマーモセット (*Callithrix jacchus*) は、神経科学および生物医学研究における重要な非ヒト霊長類モデルである。しかし、既存の 3D リソースは主に脳アトラスやキーポイントに基づく姿勢推定に限られており、身体表面、被毛、関節構造、実験環境を統合的に扱うための再利用可能なデータ資源は十分に整備されていない。本研究では、コモンマーモセットの身体–環境相互作用を三次元的に再現するためのマルチモーダルデータセットを構築した。本データセットには、CT 画像に基づく全身表面メッシュ、写真参照に基づく被毛表現、姿勢駆動のためのリギング済み 3D モデル、3 個体・約 90 時間・8 視点の同期行動動画、2D/3D キーポイント推定データ、図面情報に基づく 3D 実験環境モデル、および姿勢推定結果と 3D モデルを統合した疑似一人称視点レンダリングが含まれる。Technical validation により、CT 由来メッシュと表面モデルの幾何的一致、2D/3D キーポイント推定の精度、環境モデルの寸法精度、実画像とレンダリング画像の構造的類似性を評価した。本データセットは、マーモセットの自然行動を点列としてだけでなく、身体形状と環境との関係を含む三次元現象として扱うための基盤を提供し、行動解析、可視化、合成データ生成、および将来的なデジタルツイン型研究への応用を可能にする。

## Background & Summary

コモンマーモセット (*Callithrix jacchus*) は、小型で飼育・繁殖が比較的容易であり、世代時間が短く、遺伝子改変技術とも親和性が高い一方で、霊長類としての高次の感覚・認知・社会行動を示すことから、近年、神経科学および生物医学研究における重要な非ヒト霊長類モデルとして位置づけられている [1, 2]。とくに、協同養育、食物分配、社会的相互作用といった行動的特徴は、ヒトに近い社会行動や社会認知の神経基盤を検討するうえで魅力的であり、さらに神経発達障害や神経変性疾患を含む疾患モデル研究への展開も強く期待されている [3]。近年は、こうした自然行動を三次元的に定量化する流れが加速しており、3D 姿勢時系列から社会的・認知的・病態的特徴を読み解く研究 [4] や、複数個体の 3D 姿勢をリアルタイムに追跡して closed-loop 実験へ接続する研究 [5] が相次いで報告されている。

一方で、コモンマーモセットにおける既存の 3D 資源は、主として神経解剖学的アトラス [6]、あるいはキーポイントや軌跡の再構成を目的とした姿勢推定基盤に集中している [4, 5, 7]。これらの資源は、脳空間の標準参照枠を与えたり、自然行動を高スループットに定量したりするうえで極めて重要であるが、主眼はあくまで脳座標空間あるいは身体部位の時空間座標の取得にあり、身体そのものの外表面、被毛、rig、さらに動物が相互作用する実験環境を一体として記述することには置かれていない。そのため、マーモセットの行動を「点列」としてではなく、身体と環境の関係を含んだ視覚的・空間的な現象として再表現する層には、なお大きな余地が残されている。

このギャップは、他種で進みつつある 3D 身体モデル研究と比較すると、より明確になる。マウスでは、CT に基づく三次元仮想個体が構築され、2D/3D 姿勢推定のための合成学習データと正解ラベルの生成に利用されている [8]。ラットでは、biomechanically realistic な virtual rodent が自然行動を模倣するように学習され、その内部表現が実ラットの行動下における神経活動構造を予測することが示された [9]。さらにマカクザルでは、自由行動下の 3D 姿勢推定を実現する OpenMonkeyStudio [10] に加え、統制された視覚・社会刺激生成のためのパラメトリック 3D 顔モデル [11] など、3D 情報を用いた行動計測やレンダリング可能なモデル資源の有用性がすでに示されている。

本研究では、このような背景を踏まえ、コモンマーモセットに対して、CT に基づく全身表面モデル、写真参照に基づく被毛表現、行動同期のための rig、ならびに実験ケージおよび周辺環境を含む 3D 環境モデルを統合した再利用可能資源を構築した。被毛表現については、Blender 上での高忠実度な Hair Curves による実装に加え、Unity や Unreal Engine など他の描画環境でも利用しやすい軽量表現を別途用意することで、特定ソフトウェアに閉じない資源化を目指した。また、姿勢推定データと 3D 身体モデルおよび 3D 環境モデルを同期させることで、キーポイント列だけでは把握しにくい身体-環境相互作用を、空間的に一貫した形で可視化できるようにした。Digital twin は一般に、現実対象のデジタル表現を実測データと結びつけて理解・解析・予測に活用する枠組みとして捉えられており [12]、本資源はマーモセット研究におけるその基盤を担うものとして位置づけられる。将来的には、マーモセットの疑似的一人称視点再構成や、より高度な行動シミュレーションへの発展も期待される。

本 Data Descriptor で公開する資源には、現段階で二つの適用上の制約がある。第一に、3D 身体モデルの基礎となる CT は 1 個体から取得されている一方、

行動動画は CT 個体とは異なる 3 個体から取得されており、本資源は厳密な意味での individual-specific digital twin というより、行動データと同期可能な高忠実度 3D 基盤として解釈されるべきである。第二に、現時点での姿勢同期と technical validation は、ケージ内に 1 個体のみが存在する条件を主たる対象としている。これは、尾部キーポイントを含む 2D 推定が、複数個体が近接して同一バウンディングボックス内に入る状況で不安定化しやすいためである。もっとも、この適用範囲においても、体表、被毛、rig、環境との位置関係を安定に統合できることは、マーモセットの身体-環境相互作用を高精細に可視化するうえで十分に重要であり、今後の多個体拡張に向けた実践的な基盤になる。

## Method

### Workflow

本データセットの workflow を Figure 1a に示す。この図の横方向に伸びている系列で、オレンジの系列は CT スキャン画像から 3D マーモセットモデルを作成する方法、緑色の系列は動画から 2D/3D キーポイント推定を行う方法、青色の系列は図面から 3D 環境モデルを作成する方法をそれぞれ示している。最終的に、作成した 3D マーモセットモデルと 3D 環境モデルを組み合わせて、マーモセットの行動を 3D 上で再現を行う 3D digital twin marmoset を作成し、それぞれの結果に対して validation を行った。

Figure1b に、3D digital twin marmoset による digital twin と現実の撮影環境の再現結果を示す。左が実際に撮影されたデータで、右がコンピュータ上に再現したデータ。形状、色、配置などに少しのずれがあるものの、全体的にマーモセットの外観と撮影環境の構造を再現できていることがわかる。このような 3D digital twin marmoset を作成するための方法の流れを、以下のセクションで説明する。

### Animals

本研究では、コモンマーモセット (*Callithrix jacchus*) を用いて 2 種類のデータ取得を行った。3D マーモセットモデルの作成を目的とした CT 撮影と、3D 姿勢推定を目的とした行動動画の撮影である。CT 撮影と行動動画撮影にはそれぞれ異なる個体を使用した。

CT 撮影には 1 個体のオスのコモンマーモセット (5 歳 8 ヶ月齢、体重 291 g) を使用した。本個体は、公益財団法人実験動物中央研究所 (CIEM) より提供されたものであり、同研究所の動物実験委員会により承認された実験計画に基づき飼育・管理されたものである。

行動動画の撮影には 1 に示す 3 個体のコモンマーモセット (メス 2 個体、オス 1 個体) を使用した。3 個体はそれぞれ京都大学ヒト行動進化研究センター (Center for the Evolutionary Origins of the Human Behavior, Kyoto University) において飼育された。本データセットは個体すべてにおいて健常期のみの行動データが含まれる。行動の撮影は専用の撮影スペースにおいて実施した (撮影環境の詳細は「動画データの取得」セクションで記述する)。行動撮影に関するすべての動物実験は、京都大学ヒト行動進化研究センターの動物福祉・動物管理委員会 (the




Figure 1: (a) 3D デジタルツインマーモセット個体・環境構築およびデータセット作成ワークフロー。オレンジの系列はマーモセットの CT スキャン画像からコンピュータ上で動作する 3D マーモセットの作成方法、緑色の系列はマーモセットを撮影した動画から 3D 姿勢推定を行う方法、青色の系列は撮影環境のケージと骨組みの図面から 3D 環境を作成する方法をそれぞれ示している。図面に記載のない箇所については実験環境の画像からおおよその位置を特定し、カメラパラメータの調整と合わせて最終的な位置を決定した。撮影環境に設置されたカメラなどの備品も一部 3D 環境モデルで再現を行いデジタルツイン環境を作成した。最終的に、作成した 3D マーモセットモデルと 3D 環境モデルを組み合わせ、マーモセットの行動を 3D 上で再現を行い、それぞれの method の validation を行った。(b) 3D digital twin marmoset による digital twin と現実の撮影環境の再現結果。左が実際に撮影されたデータで、右がコンピュータ上に再現したデータ。

Animal Welfare and Animal Care Committee of the Center for the Evolutionary Origins of the Human Behavior, Kyoto University) の承認を受けて実施された。すべての実験手続きは、同センターが定める霊長類の飼育管理に関するガイドライン (the Guidelines for Care and Use of Nonhuman Primates) に従って行った。

Table 1: Details of the individual common marmosets recorded in measurement environment

| ID | Sex    | Date of Birth | Measurement Duration    | Measurement Hours |
|----|--------|---------------|-------------------------|-------------------|
| A  | Female | 2018/05/28    | 2021/04/26 – 2021/10/08 | 55.46             |
| B  | Male   | 2014/04/11    | 2021/08/27 – 2023/03/13 | 33.38             |
| C  | Female | 2011/11/21    | 2021/10/09 – 2021/10/10 | 1.33              |

## CT 画像取得

全身 CT 画像は、Aquilion ONE TSX-306A (Canon Medical Systems) を用いて取得した。マーモセットは Figure 1b に示す姿勢で撮影された。撮影条件は以下の通りである：管電圧 120kV、管電流 150mA、実効管電流時間積 92mAs、スキャン速度 0.5s/rot、撮像時間 4.9s。得られた CT 画像の面内分解能は  $200\mu\text{m} \times 200\mu\text{m}$ 、スライス厚は  $300\mu\text{m}$  であった。被爆線量の指標として  $\text{CTDI}_{\text{vol}}$  は 11.1mGy、DLP は  $343.1\text{mGy} \cdot \text{cm}$  であった。

## CT データのセグメンテーション

得られた CT 画像からマーモセットの体表面形状を抽出するため、MATLAB を用いて前処理パイプラインを実装した (Figure 2a)。まず、CT スキャンの生データからマーモセットが収容された金属製円筒内の領域を抽出した。次に、抽出されたマーモセットの身体領域に対して、画像処理に基づく穴埋め処理および 100 ボクセル未満の小領域の除去を行った。最後に、全体的なスムージングを適用することで、CT 由来のマーモセットの皮膚表面のマスクを得た。ただし、CT スキャンの空間分解能の限界やセグメンテーション処理に起因して、得られた表面メッシュには顔・手周辺のギザギザした形状が残存していた。また、本個体は頭蓋骨に損傷があったため、頭部表面に穴が生じていた。

## 表面モデルの作成

このように得られたセグメンテーション由来の体表面メッシュには、上述のような形状の粗さや欠損が含まれていたため、これらを修正した 3D マーモセット表面モデルを Blender を用いて手作業で作成した (Figure 2a)。表面モデルの作成には Blender を使用した。作成した表面モデルの形状精度は、セグメンテーション由来のメッシュとの比較によって評価した。評価指標として Hausdorff 距離および Dice 係数を用いた。




Figure 2: (a) 3D マーモセット作成方法。CT スキャン画像から画像処理によって緑色で示しているセグメンテーションデータを作成した。セグメンテーションを3D メッシュに変換することで、赤色で示しているセグメンテーション由来のマーモセット表面モデルを得た。その赤色のメッシュに合致するように灰色で示しているマーモセット表面モデルを人の手によって作成した。表面モデルにテクスチャ付きの毛と皮膚を適用して3D マーモセットモデルを作成した。毛の表現が軽量の3D マーモセットモデルも作成した。そして、作成した3D マーモセット表面モデルの形状精度を、Hausdorff 距離と Dice 係数を用いて、セグメンテーション由来のメッシュとの比較によって評価した。(b) リギングした IK ボーン、Armature ボーンと3D キーポイントとの対応。3D マーモセットにリギングされたそれぞれのボーンと Figure 3c で説明されている3D キーポイントがどのような対応関係にあるかを示す。ほとんどの3D キーポイントと IK ボーンは1:1 対応しているが、shoulder と hip に関しては3次元空間での中点を計算したものと IK ボーンが対応している。IK ボーンや Armature ボーンがどのようにリギングされているかは公開リポジトリを参照すること。

## 毛と皮膚のテクスチャの適用

作成した表面モデルに対して、マーモセットの外観を再現するために毛 (fur) を追加した (Figure 2a)。毛の生成には Blender の Hair Curves 機能を使用した。毛の形状は、実際のマーモセットの写真を参照しながら手作業で調整した。毛の色については、GNU Image Manipulation Program 画像編集ソフトのスポイト機能を用いて実際のマーモセットの写真から毛色を抽出し最終的に主観で特定した。特定した毛色を Blender 上の Hair Curves に適用し、実際の外観と一致するよう微調整を行った。毛のパラメータの詳細は公開されている Blender ファイルを参照されたい。

## リギング

作成した 3D マーモセット表面モデルに対して、Blender 上で関節階層 (アーマチュア) を設定してリギングを行った。アーマチュアは Base → Body → Chest → Neck → Head の体幹階層を中心に、左右の上肢 (Shoulder → UpperArm → Forearm → Hand、各指のボーンを含む)、左右の下肢 (Pelvis → UpperLeg → LowerLeg → Foot、各趾のボーンを含む)、および尾部から構成される。さらに、姿勢推定結果に基づくアニメーションの制御のため、13 個の IK ボーン (Chest\_IK、Head\_IK、Foot\_IK.L/R、Knee\_IK.L/R、Forearm\_IK.L/R、Elbow\_IK.L/R、Tail\_IK、Tail0\_IK、Chest\_Control\_IK) を設定した。ボーン階層の完全な一覧は公開リポジトリを参照されたい。3D 姿勢推定で得られたキーポイント位置と、リギングされた 3D マーモセットの IK ボーン位置の対応付けを行った (Figure 2b)。対応付けの結果、姿勢推定結果に基づく 3D マーモセットモデルのアニメーションを実現した。

## 動画データの取得

マーモセットの行動を 8 方向から同時に記録するため、ケージの周囲に Basler acA2040-35gc (Basler AG) カメラを 8 台配置した (Figure 3a)。各カメラには Theia ML410 4 – 10 mm レンズを装着した。映像の録画には Motif システム (Loopbio, Lange G, Wien, Austria) を使用した。解像度は 2048 × 1536 ピクセル、フレームレートは 24 fps に設定した。実際には動画データは 24fps で撮影されているが、motif 録画システムの関係上 25fps で保存されている。そのため前処理段階で 24fps に変換して使用している。Table 1 で示しているように、全 3 個体にわたり、合計 242 セッション、総フレーム数 7,790,723 フレーム (約 90 時間) の行動データを取得した。個体ごとの内訳は個体 A が 168 セッション (4,791,838 フレーム)、個体 B が 71 セッション (2,883,861 フレーム)、個体 C が 4 セッション (115,024 フレーム) であった。

カメラキャリブレーションは OpenCV フレームワークを用いて実施した。内部パラメータ (レンズ歪み係数等) は、各カメラで撮影したチェッカーボードパターンの画像を cv2.omnidir.calibrate に入力して取得した。外部パラメータ (カメラ位置等) は、撮影空間内のランドマーク位置の 3D 座標とそのカメラ画像上への 2D 投影座標を cv2.solvePnP 関数に入力して初期化した。さらに、ケージ内で移動させた小物体 (ピンポン球) の軌跡の投影誤差を最小化することで、内部パラメータと外部パラメータの同時最適化を行い、キャリブレーション精度を向

上させた。




Figure 3: 3D キーポイント取得方法、ケージ・フレーム図面、擬似視点推定方法。(a) 八方向のカメラからマーモセットを撮影した画像。(b) 撮影されたマーモセットに対して Bounding Box 検出器と 2D 姿勢推定ネットワークを用いた 2D 姿勢推定方法。(c) 姿勢推定の際に設定されたキーポイント部位とそれぞれの部位に対応する名前と番号、およびスケルトン。左の画像は頭周辺を拡大して表示しており、右の画像は体全体を表示している。(d) 3D 姿勢推定方法。左の画像は撮影に用いたカメラのキャリブレーションによって推定されたカメラ位置、方向を示している。右の画像はカメラを用いて 3D 姿勢推定を行う際の一例。実際の画像の 2D キーポイント位置と、各カメラの位置関係によって 3D 姿勢推定を行う。(e) ケージおよびフレームの図面。図面に記載のない箇所については実験環境の画像からおおよその位置を特定し、カメラパラメータの調整と合わせて最終的な位置を決定した。(f) ケージ・フレームの図面をもとに作成した 3D 環境モデルの一例。e に示している B 方向からレンダリングした画像であり、一部の緑のカーテンやフレーム、カメラは消した状態で表示している。

## 2D/3D キーポイント推定

マルチビュー動画からマーモセットの 3D 姿勢を推定するため、3 段階のアプローチを採用した。まず各カメラ画像から Bounding Box を検出し、次に 2D キーポイントを推定し、最後にマルチビューの 2D キーポイントから 3D キーポイントを再構成した (Figure 3a-d)。



## Bounding Box 検出

各カメラ画像に対して、YOLOX アーキテクチャ [13] に基づく Bounding Box 検出器を用いてマーモセットの領域を検出した (Figure 3b)。検出器の学習には mmdetection (v2.26.0) を使用した。学習データにはアノテーションデータが入っている Zenodo[19] 公開データを改変して用いた。検出器の事前学習モデルには、先行研究で作成された尻尾が含まれていない検出器を用いた。アノテーションデータと事前学習モデルをもとに尻尾を含んだ Bounding Box 検出器をファインチューニングした。学習に使った画像数は約 3000 枚で train/test の比率は 8:2 とした。学習は GPU (NVIDIA A100) を用いて約 1 時間で完了した。以降の GPU 表記されている箇所はすべて同様の環境で学習を行った。モデルの学習結果は、テストデータに対する mAP が最大となるエポックのモデルを採用した。mAP とは、mean Average Precision の略で、COCO 評価プロトコル [14] に基づく Bounding Box の平均適合率を指す。mAP は、予測されたバウンディングボックスと正解アノテーションの重なり度合い (Intersection over Union; IoU) の閾値を 0.50 から 0.95 まで 0.05 刻みで変化させた際の平均として算出される。

## 2D キーポイント推定

2D 姿勢推定には HRNet-w48-DEKR[15] アーキテクチャを採用し、mmpose(0.29.0) を用いて学習を行った。姿勢推定の事前学習モデルには、先行研究で作成された尻尾を含まない姿勢推定モデルを用いて、尻尾 2 点を追加した 20 キーポイントの姿勢推定モデルをファインチューニングした。学習に使った画像数は Bounding Box 学習と同様。学習は GPU を用いて約 2 時間で完了した。モデルの学習結果は、テストデータに対する mAP が最大となるエポックのモデルを採用した。また、その際の姿勢推定に使用するキーポイント定義は、マーモセットの体表面上に 20 個の部位とした (Figure 3c)。キーポイントは nose、L/R eye、L/R ear、L/R shoulder、L/R elbow、L/R wrist、L/R hip、L/R knee、L/R ankle、backbone peak、tail\_1、tail\_2 の 20 点から構成されている。2D キーポイント推定の精度を評価するため、テストデータに対する平均ピクセル誤差を計算した。

ポーズ推定モデルの精度評価も、COCO 評価プロトコルに基づく mAP を用いた。ポーズ推定における mAP は、物体検出で用いられる IoU (Intersection over Union) の代わりに、OKS (Object Keypoint Similarity) を類似度指標として使用する。OKS は以下の式で定義される：

$$OKS = \frac{\sum_i \exp\left(-\frac{d_i^2}{2s^2\sigma_i^2}\right) \delta(v_i > 0)}{\sum_i \delta(v_i > 0)}$$

ここで、 $d_i$  は予測キーポイント  $i$  と正解キーポイント間のユークリッド距離、 $s$  はオブジェクトのスケール (セグメンテーション面積の平方根)、 $\sigma_i$  はキーポイント  $i$  に固有の定数、 $v_i$  は正解キーポイントの可視性フラグである。OKS は 0 から 1 の値を取り、1 に近いほど予測が正解に近いことを示す。この OKS を閾値として、各閾値における Precision-Recall 曲線下面積から AP を算出する。本研究では、mAP が最大となった姿勢推定モデルを採用した。 $\sigma_i$  の値は、COCO ヒト姿勢推定ベンチマークにおいて複数アノテータ間の標準偏差から算出された値を、対応するキーポイント (nose, eyes, ears, shoulders, elbows, wrists, hips, knees,

ankles) に対してそのまま採用した (Lin et al., 2014)。追加キーポイント (back, tail\_1, tail\_2) については  $\sigma = 0.089$  を設定した。これらの  $\sigma$  値はマーモセット固有のアノテーション分散から算出されたものではなく、マーモセットと人体ではキーポイントの局在化の難易度が異なる可能性がある。

### 3D キーポイント再構成

最終的に 8 方向のカメラで推定された 2D キーポイントと、キャリブレーションにより得られたカメラパラメータを用いて、3D キーポイント座標を再構成した (Figure 3d)。3D 再構成は、実行スクリプトが入っている Zenodo[20] を用いて実施した。詳細は、まず各フレームにおいて異なるカメラ間の Bounding Box を幾何学的整合性に基づきグルーピングし、三角測量により 3D 姿勢を構成した。次に、隣接するキーフレーム間の 3D 姿勢をハンガリアンアルゴリズムにより時間的に対応付けた。そして、各 3D トラックレットに対して個体 ID を割り当て、分断されたトラックレットの統合と最終的な平滑化を行った。最終的に、個体ごとの 3D 姿勢時系列データは anipose[16] により時空間的に平滑化・正規化した。各段階の詳細なアルゴリズムおよびハイパーパラメータについては Kaneko et al.[4] を参照されたい。

3D キーポイント再構成の精度を評価するため、ground truth として 2D キーポイントを人の手で指定した時と推定値の 2D キーポイント推定モデルで推定した 3D キーポイントの誤差を計算した。また、実際に推定された 3D キーポイントの品質を評価するために、再投影誤差を計算した。再投影とは、カメラのキャリブレーションデータからカメラの 3 次元上での位置とレンズの歪みがわかっていることを利用して、画像の歪みを補正してカメラ位置をもとに 3 次元座標をカメラの 2 次元座標に変換することである。再投影誤差とは、ground truth として 3D キーポイントを 2D キーポイントに再投影した時の座標と、推定された 2D キーポイントの座標の誤差を計算したものである。

### 3D 環境の構築

3D 環境モデルの構築をするために、ケージおよび外側フレームの図面情報を使用した (Figure 3e)。図面上の各部位には番号が割り振られており、ケージの大きさおよび外側フレームの寸法情報を抽出した。モデリングには Blender v4.5.0 を使用し、抽出した寸法に基づいてケージおよび枠組みの 3D モデルを作成した。作成したモデルの各部の寸法は Blender に備え付けられている Python 機能と作成した Python プログラムによって計測し、図面の値に近づくよう調整を行なった。背景の緑のカーテンやカメラ付近の緑色のシート、カメラが設置されている骨組みの高さについて記載がなかったため、実際の撮影画像と比較し可能な限り一致するように作成した。その中にケージを配置し、撮影カメラからの画像の写り方と大まかに合うように、初期配置を決めた。その後、カメラの歪みパラメータおよび 3 次元空間上のカメラ位置を、実撮影画像とレンダリング画像が視覚的に整合するよう手動で調整した。実験環境のカーテンの色や照明についても、実際の撮影画像とレンダリング画像を比較しながら、Blender 上のマテリアルの色・光量を調整した。その結果として Figure 3f のような 3D 環境モデルを作成した。ここでは Figure 3e で示されている B 方向からの視点での 3D 環境モデルを示し

ており、緑のカーテンやフレームを一部消している。最終的な 3D 環境・計測スクリプト・カメラパラメータは公開リポジトリを参照されたい。

### 3D デジタルツインの構築

作成した 3D マーモセットモデル・3D キーポイント・3D 環境モデルを組み合わせて、マーモセットの行動を 3D 上で再現するための 3D デジタルツイン環境を構築した (Figure 1b)。微調整として、3D キーポイントの位置に基づいて、リギングされた 3D マーモセットモデルの IK ボーンを制御することで、マーモセットの行動を 3D 上で再現した。その際に、3D キーポイントは実際の空間の絶対座標に基づいており、Blender 上の 3D マーモセットモデルの IK ボーンはマーモセットモデルの Base ボーンを原点とする相対座標で制御されているため、3D キーポイントの座標を Blender 上のマーモセットモデルの座標に変換を行い、キーポイントの適用を行った。その結果、3D マーモセットモデルが 3D キーポイントの位置に基づいて動作することができた。Figure 1b の実際の動画をリポジトリに公開しているので、そちらも参照されたい。

### 疑似視点推定

マーモセットの視線方向を推定するため、推定された両耳と両目の位置を用いて疑似視点ベクトルを作成した (Figure S1)。両耳の midpoint と両目の midpoint を結ぶ線をもとに疑似視点の方向を定義し、マーモセット視点カメラの向きを設定した。カメラの原点位置は、キーポイント推定された両目の midpoint 位置に設定した。注意点として、この方法で用いた方向は実際のマーモセットの視線方向と完全に一致するわけではないため、あくまで疑似的な視点推定であることを留意すること。疑似視点カメラの視野角は Troilo et al.[17] の報告で、コモンマーモセットの片眼の視野角が水平方向約-60° 100°、垂直方向約-70° 70° であることが示されている。本研究では疑似的に両眼の映像を出力するため、水平方向-100° 100°、垂直方向-70° 70° の視野角を設定した。Blender のカメラのセンサーサイズおよび焦点距離は、この視野角が再現されるよう調整した。レンダリングには Blender の Cycles レンダリングエンジンを GPU 上で行なった。Blender カメラの種類は Equirectangular に設定した。解像度は 1000 x 700 ピクセルに設定した。最大サンプル数は 500 に設定した。照明は作成した 3D 環境モデル内の光源を使用した。出力形式は MP4 (24 fps) とし、今回は 1 セッションの動画を生成した。

## Data Records

3D digital twin marmoset の一部を Zenodo に公開し、全体のデータは AWS にて公開している。この公開データには、CT データ、2D 姿勢推定学習データ、3 個体を撮影した動画データ、学習済み 2D キーポイント推定モデル、2D・3D キーポイント時系列データ、レンダリングした疑似視点データ、SSIM および PSNR を算出したデータが含まれている。3D digital twin marmoset フォルダの構造を Figure 4 に示す。この公開データは 3D\_marmoset\_body\_data, marmoset\_keypoint\_data, 3D\_environmental\_data, 3D\_digital\_twin\_data の 4 つのサブフォルダから構成されている。

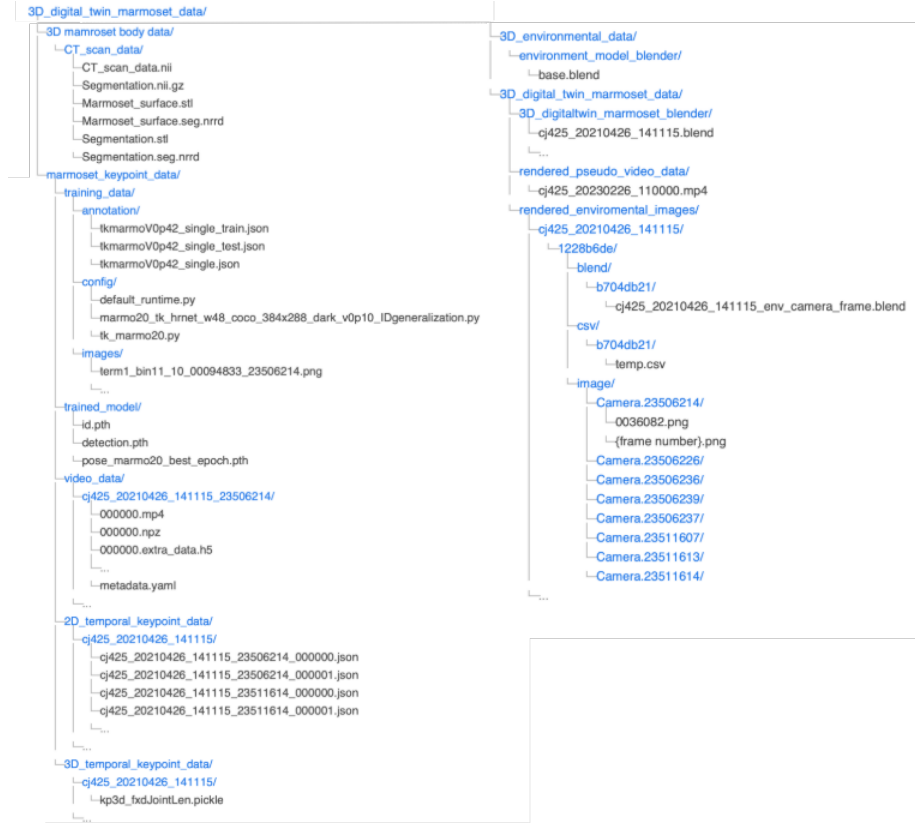


Figure 4: 3D digital twin marmoset フォルダの構造。このフォルダは 3D\_marmoset\_body\_data, marmoset\_keypoint\_data, 3D\_environmental\_data, 3D\_digital\_twin\_data の 4 つのサブフォルダから構成されている。さらに、3D\_marmoset\_body\_data には CT データ、セグメンテーションデータと表面モデルデータが格納されている。marmoset\_keypoint\_data には、学習に使用したアノテーションデータと画像データ、動画データ、学習済みモデル、推定された 2D・3D キーポイントデータが格納されている。3D\_environmental\_data には、3D 環境モデルの Blender ファイルが格納されている。3D\_digital\_twin\_data には、全てを統合した blender ファイル、レンダリングした擬似視点データと SSIM および PSNR を算出したデータが格納されている。

## 3D marmoset data

### CT データ

CT データは 3D\_marmoset\_body\_data の中の CT\_scan\_data フォルダに格納されている。CT データは、CT\_scan\_data.nii という名前で保存されている。セグメンテーション後のデータは Segmentation.nii.gz という名前で保存されている。セグメンテーションのメッシュデータは Segmentation.stl という名前で保存されている。表面モデルデータは Marmoset\_surface.stl という名前で保存されている。Hausdorff 距離と Dice 係数の比較には特定のセグメンテーションデータである必要があるため、セグメンテーションと表面モデルの両方のデータを .nrrd のファイル形式で保存している。

NIFTI フォーマットで保存されている CT データとセグメンテーションデータは、.nii および .nii.gz のファイル形式で保存されている。セグメンテーションのメッシュデータと表面モデルデータは、STL ファイル形式で保存されている。

## Marmoset keypoint data

### Training data

学習データは marmoset\_keypoint\_data の中の training\_data フォルダに格納されている。training\_data フォルダには annotation、config、image の 3 つのサブフォルダがある。annotation フォルダには、Bounding Box 検出および 2D キーポイント推定の学習に使用したアノテーションデータが格納されている。config フォルダには、mmdetection (2.26.0) および mmpose (0.29.0) の学習に使用したモデルの設定ファイルが格納されている。image フォルダには、学習に使用した画像データが格納されている。annotation フォルダには、Bounding Box 検出用のアノテーションファイルとキーポイント推定用のアノテーションファイルがそれぞれ JSON 形式で格納されている。ファイル名は train.json および test.json であり、学習データとテストデータに対応している。config フォルダには、検出モデルおよび姿勢推定モデルの設定ファイルがそれぞれ .py 形式で格納されている。学習に使用した画像数は合計約 3,000 枚であり、train/test の比率は 8:2 とした。アノテーションデータは COCO フォーマットに準拠した JSON 形式で保存されている。設定ファイルは Python 形式 (.py) で保存されている。画像データは JPEG 形式 (.jpg) で保存されている。アノテーションの JSON ファイルは、COCO データセットフォーマットに準拠しており、images、annotations、categories の 3 つの主要なキーから構成されている。images には各画像のファイル名、画像 ID、解像度（幅・高さ）が記録されている。annotations には各画像に対応する Bounding Box 座標（COCO 形式：[x, y, width, height]）および 20 個のキーポイント座標（[x, y, visibility] の繰り返し）が記録されている。categories にはマーモセットのカテゴリ情報およびキーポイントの名前とスケルトン接続情報が記録されている。

### 学習済みモデル

学習済みモデルは trained\_model に格納されており、学習済み 2D キーポイント推定モデル、id モデル及び Bounding Box 検出モデルの重みが入っている。2D キーポイント推定モデル、id モデル、Bounding Box 検出モデルの重みは、pth ファイル形式で

保存されている。2D キーポイント推定モデルは pose\_marmo20\_best\_epoch.pth、id モデルは id.pth、Bounding Box 検出モデルは detection.pth という名前で保存されている。

## Video Data

video\_data の中には、動画データが格納されている。動画データは、個体 ID とセッション ID を組み合わせた名前のフォルダに格納されている。動画データのフォルダ名は、dailylife\_{個体 ID}\_{yyyymmdd}\_{hhmmss}\_{camid}、または、{個体 ID}\_{yyyymmdd}\_{hhmmss}\_{camid} というフォルダの中に格納されている。個体 ID は、A、B、C の 3 種類で 1、実際はそれぞれ cj611、cj425、cj357 という ID が割り振られている。yyyymmdd は撮影日、hhmmss は撮影開始時間 (10000 フレームごとに録画されており実際の正確な時間とは異なる。録画開始が 090000 であれば 10000 フレーム録画後は 100000 になる)、camid はカメラ ID を表す。camid は 8 種類あり Figure 3 では cam1 から cam8 として紹介しているが実際の camid とは異なる。cam number と camid の対応は、Table 2 に示す。親フォルダの中に、撮影動画データ (.mp4) と motif システムのログデータ (.npz, .h5) が格納されている。撮影動画データは 10000 フレームごとに分割されて保存されており、10000 フレーム以内に撮影が終了した場合は、そのフレーム数に応じて保存される。動画データの解像度は 2048 × 1536 ピクセル、フレームレートは 24 fps、コーデックは H.264 である。npz ファイルはそれぞれのビデオチャンク (000000.mp4 であれば 000000.npz) に対応しており、ビデオチャンク内のフレームごとのタイムスタンプやカメラの露出時間などのメタデータが格納されている。h5 ファイルはそれぞれのビデオチャンク (000000.mp4 であれば 000000.extra\_data.h5) に対応しており、ビデオチャンク内のフレームごとのカメラの撮影タイミングの情報が格納されている。

## 2D キーポイントデータ

2D\_temporal\_keypoint の中には、推定された 2D キーポイント座標データが格納されている。dailylife\_{個体 ID}\_{yyyymmdd}\_{hhmmss}、または、{個体 ID}\_{yyyymmdd}\_{hhmmss} という名前のフォルダの中に、実際の json 形式の 2D キーポイントデータが格納されている。json ファイルの名前は、dailylife\_{個体 ID}\_{yyyymmdd}\_{hhmmss}\_{camid}.json、{個体 ID}\_{yyyymmdd}\_{hhmmss}\_{camid}.json である。2D キーポイントデータは、動画データから 2D キーポイント推定によって出力されたもので、動画データの親フォルダの名前がファイル名として用いられている。json ファイルには、動画データのフレームごとに推定された 20 個のキーポイントの座標が格納されている。

## 3D キーポイントデータ

3D キーポイントデータは 3D\_temporal\_keypoint の中に格納されている。dailylife\_{個体 ID}\_{yyyymmdd}\_{hhmmss}、または、{個体 ID}\_{yyyymmdd}\_{hhmmss} という名前のフォルダの中に 3D キーポイントデータが格納されている。{camid} という名前のフォルダの中に、それぞれのカメラごとに推定された json 形式の 2D キーポイントデータが格納されている。3D キーポイントデータは

toml,json,pickle ファイルで構成されている。calibration.toml ファイルには、3D キーポイント再構成の際に使用されたカメラの 8 方向全ての内部パラメータと外部パラメータが格納されている。config.toml ファイルには、3D キーポイント再構成の際に使用されたアルゴリズムのハイパーパラメータが格納されている。json ファイルは、上述の 2D キーポイントデータが含まれている。pickle ファイルには、動画データのフレームごとに推定された 20 個のキーポイントの 3D 座標が格納されている。

### 3D environment data

environment\_model\_blender の中に、base.blend ファイルが格納されている。base.blend ファイルには、図面情報から作成されたケージの 3D モデル、撮影空間の 3D モデル、および CT scan から作成された 3D マーモセットモデルが含まれている。blender ファイル形式で保存されている。base.blend ファイルは Blender のコレクション機能を用いて、ケージの 3D モデル、撮影空間の 3D モデル、および CT scan から作成された 3D マーモセットモデルをそれぞれ別のコレクションに格納している。

### 3D digital twin data

3D\_digitaltwin\_marmoset\_blender の中には、3D マーモセット、3D キーポイント、3D 環境モデル全てが統合された、.blend ファイルが格納されている。blend ファイルの名前は、dailylife\_{個体 ID}\_{yyyymmdd}\_{hhmmss}.blend、{個体 ID}\_{yyyymmdd}\_{hhmmss}.blend である。ファイル形式は blender ファイル形式で保存されている。ここに含まれる全ての blender ファイルは 3D environment data の base.blend 内にある 3D マーモセットに 3D キーポイントを設定した状態の blender ファイルである。Blender の Timeline ウィンドウに、動画データのフレームごとに推定された 20 個のキーポイントの 3D 座標が格納されていることが確認できる。

### レンダリングした擬似視点データ

レンダリングした擬似視点データは rendered\_pseudo\_view の中に格納されている。動画ファイルの形式は mp4 (H.264) である。

### レンダリングされた 3D 環境画像

rendered\_environmental\_images の中には、SSIM および PSNR を算出した際の 3D 環境画像データが格納されている。フォルダ名はセッション毎に分かれており、dailylife\_{個体 ID}\_{yyyymmdd}\_{hhmmss}、または、{個体 ID}\_{yyyymmdd}\_{hhmmss} というフォルダの中に格納されている。使用した blender, csv ファイルの再現性確保のため hash を計算しており、フォルダ名に hash 値を付けている。使用した base blender のサイズによって hash 値を計算している。(Figure 4 の rendered\_for\_ssim\_psnr の下の hash\_1 がこれに該当する) 使用した csv ファイルのサイズによっても hash 値を計算している。(Figure 4 の rendered\_for\_ssim\_psnr の下の hash\_2 がこれに該当する) image フォルダの中に

は、SSIM および PSNR を算出する際に使用した動画データが格納されている。blend, csv, png, json が含まれている。blend には 3D モデルマーモセットと 3D で再現した環境が入っている。3D モデルマーモセットには 3D キーポイント情報が含まれているため blender 上でフレーム毎に姿勢情報が含まれている。csv には blender の 3D モデルマーモセットに設定した 3D 姿勢推定データが入っている。列に pts\_key\_x,y,z のようなキーポイント位置の情報があり、行に 1,2,3,... などのフレーム番号順に並んでいる。png は 3D モデルマーモセットに姿勢を設定した状態でレンダリングした画像である。解像度は 2048x1536。これらの画像と実際の画像を用いて SSIM と PSNR を計算する。

Table 2: Camera numbering correspondence

| Camera Number | Camera ID |
|---------------|-----------|
| cam1          | 23506226  |
| cam2          | 23511607  |
| cam3          | 23506214  |
| cam4          | 23506236  |
| cam5          | 23511614  |
| cam6          | 23506237  |
| cam7          | 23511613  |
| cam8          | 23506239  |

## Technical Validation

### 3D マーモセット

3D マーモセットは CT スキャンをもとに手動で作成されており、皮膚の CT スキャンデータと作成した 3D マーモセットの皮膚部分のメッシュ同士の比較を行った。比較には 3D Slicer の拡張機能である SlicerRT toolkit[18] を用いて、Dice coefficient と Hausdorff Distance を計算した。Dice coefficient は二つの領域がどれだけ重なっているかを表す指標で、1 に近いほど二つの領域が重なっていることを示す。Hausdorff Distance は二つの領域の境界点同士の距離を表す指標で、0 に近いほど二つの領域が近いことを示す。

CT scan マーモセットと今回作成した 3D マーモセット表面モデルの Hausdorff 距離を視覚化したものを Figure 5a に示す。赤色のメッシュである CT scan マーモセットと 3D マーモセットの表面モデルを比較してヒートマップを作成した。ヒートマップは 3D マーモセットの表面モデル上に描画した。Hausdorff 距離は 95p の範囲に約 3.41mm で収まっている。ヒートマップは Hausdorff 距離を表しており、95p の範囲付近である 3.5mm を上限として設定した。CT scan と大きく乖離している黄色の部分は耳、背中、尾の付け根、顎付近に位置している。耳については CT scan に耳の部分が明瞭に写っておらず、実際のマーモセットの画像を元に耳を成形した。背中については CT scan データのセグメンテーション処理後に左右非対称であったことから、表面モデル作成時に左右対称になるように修正したことが原因であると考えられる。評価指標の結果は、Dice 係数 0.891、



Hausdorff 距離の平均 1.14mm (95 パーセンタイル 3.42mm) であり、CT スキャン由来のメッシュと手動作成メッシュの体積的な一致度は高い。ただし Hausdorff 距離の最大値は 15.35mm であり、局所的な形状の乖離が存在する。これは主に頭部周辺のセグメンテーションによるノイズに起因する。それ以外にも足・胴体周辺の形状の乖離と手先・足先の形状の乖離も存在する。前者はセグメンテーション処理によるノイズに起因するものであり、後者はモデリング技術の限界に起因する。

Figure 5b,c に実際のマーマセットと 3D モデルの外観比較を示す。全体的な体型・毛並みの再現が確認できる一方、上述の局所的な乖離箇所はノイズとして処理しているので作成した表面メッシュには反映されていない。また、主観的な評価であるが顔部分の目・口・耳の大きさや配置をできるだけ似せて作成した。

## 推定された 2D・3D キーポイント

Figure 6a は姿勢推定モデル学習時のテストデータに対する 2D キーポイントの誤差の大きさを示している。使用した姿勢推定モデルは mAP が最大となるエポックのモデルである。平均誤差は約 10.15px であった。部位別にみると、顔面部 (nose: 4.40px、L/R eye: 3.28/3.34px) は最も低い誤差を示し、耳 (L/R ear: 6.06/6.70px) が中程度、四肢 (shoulder, elbow, wrist, hip, knee, ankle: 8.56 – 12.86px) および体幹・尾部 (backbone: 14.73px、tail1/tail2: 16.12/16.70px) では誤差が大きかった。

Figure 6b は 3D キーポイントの平均誤差の大きさを示している。誤差の大きさは ground truth と推定値の差を元に計算した。ground truth が人手でアノテーションした 2D キーポイントから三角測量した 3D 座標で、推定値が姿勢推定モデル推定の 2D キーポイントから三角測量した 3D 座標であり、その差を誤差として定義している。本データセットの 3D キーポイント平均誤差は約 12.73mm (範囲 6.89 – 21.51mm) であった。これはコモンマーマセットの体長約 200mm に対して約 6.4% に相当する。部位別では、顔面部 (nose: 6.89mm、L/R eye: 7.27/7.55mm) が最も低く、四肢・体幹部は概ね 10 – 19mm の範囲であった。2D 誤差と 3D 誤差の部位別の傾向は概ね一致しており、例として 2D 推定精度が高い顔面部では 3D 誤差も小さく、2D 誤差の大きい四肢・体幹部では 3D 誤差も大きかった。参考として 3D キーポイントの誤差を 3 次元空間に示した図を Figure 6c に示す。

## 再投影誤差

テストデータへの 3D キーポイント誤差は上記の通りだが、これはアノテーション付きの限られたフレームでの評価である。データセット全体の品質を評価するため、全フレームにおける再投影誤差を算出した。再投影誤差の計測には、カメラのキャリブレーションデータと全てのフレームで推定した 2D と 3D キーポイントデータを用いた。全てのカメラにおける再投影誤差の分布を Figure 6d にプロットした。再投影誤差の平均は約 11.82px である。これは横の撮影解像度 2048px に対して約 0.6% に相当する。そして p95 の範囲で約 36.00px 以下に収まっている。そのため、大多数のフレームにおいて安定した 3D 再構成が行われていることが確認できた。




Figure 5: Hausdorff 距離の視覚化と実際のマーモセットと 3D マーモセットの外観比較。(a)CT スキャンと今回作成した 3D マーモセット表面モデルの Hausdorff 距離を視覚化したもの。マーモセットの CT scan からセグメンテーションして得られた表面モデルと 3D マーモセットの表面モデルを図内左に表示する。ヒートマップは 3D 表面モデル上に描画されており、Hausdorff 距離を表している。ヒートマップの上限は 95 パーセンタイル付近である 3.5mm として設定した。(b) 実際のマーモセットの画像と 3D マーモセットの画像の比較。上が実際のマーモセットの画像で、下が CT スキャンから皮膚を作成し、毛を生やした 3D マーモセットの画像である。(c) 実際のマーモセットの顔に注目した画像と 3D マーモセットの顔に注目した画像の比較。左が実際のマーモセットの顔に注目した画像で、右が 3D マーモセットの顔に注目した画像である。




Figure 6: 作成した 2D,3D キーポイントの検証結果。(a) 2D キーポイント推定の訓練に用いたテストデータとの RMSE[px]。画像上の丸は、人の手で付けられたキーポイントを中心として円の半径をそれぞれの平均の RMSE で設定し表示した。凡例に実際の誤差の平均値を示す。(b) 3D キーポイントのテストデータとの 3D 空間上の誤差 [mm]。横軸は各キーポイント番号、縦軸は mm 単位での誤差を示す。赤線はキーポイントの平均値を示す。(c) b で示した 3D キーポイント誤差大きさの可視化結果。(d) 全てのフレームでの 3D キーポイントを 3D 空間から対応するカメラ (2D) へ再投影した時の、再投影誤差の分布を示す。横軸は再投影誤差 [px]、縦軸は誤差の頻度を示す。(e) マーモセットのキーポイントごとの再投影誤差を示す。横軸は各キーポイント番号、縦軸は mm 単位での誤差を示す。青線は各キーポイントの平均値を示す。

Figure 6e に、20 個のマーモセットのキーポイントについて全フレームで平均した再投影誤差を示す。キーポイントごとの平均誤差は 6.62～14.63 ピクセルの範囲であり、全キーポイントの総平均は 11.47 ピクセルであった。鼻や両目では比較的低い誤差（6.62–7.08 ピクセル）が得られた一方、右耳および右手首では最大の誤差（それぞれ 14.58、14.63 ピクセル）を示した。95 パーセンタイル値は 15.41～31.68 ピクセルであり、左足首で最大となった（31.68 ピクセル）。

### 3D 環境モデルの幾何精度評価

作成した 3D 環境モデルの寸法精度を評価するために、実験環境の図面と 3D モデルの各部の寸法を比較した (Table 3)。全 19 箇所の計測点のうち、9 箇所は図面の値と一致しており（絶対誤差 $<10^{-3}$ mm）、残りの 10 箇所では平均約 13.3mm、最大 19.0mm の誤差が確認された。寸法比（3D モデル/図面）は全箇所では 1.00–1.04 の範囲に収まっており、すべての部位において 3D モデルが図面に対してわずかに大きい方向にずれている。最大の寸法比 1.04 は図面值 405mm の部位 (No.11) で生じたものであり、絶対誤差は 15.74mm であった。全計測点の平均絶対誤差は 7.26mm（平均寸法比 1.01）であり、3D 環境モデルは図面に対して概ね 1% 以内の精度で再現されている。

Table 3: Blueprint vs 3D model size comparison

| Blueprint object No. | MarmoCage<br>blueprint [mm] | 3D model size<br>[mm] | Absolute dif-<br>ference [mm] | Absolute ratio<br>(3D/Blueprint) |
|----------------------|-----------------------------|-----------------------|-------------------------------|----------------------------------|
| 1                    | 2220                        | 2220.00               | $< 10^{-3}$                   | 1.00                             |
| 2                    | 2100                        | 2111.11               | 11.11                         | 1.01                             |
| 3                    | 2200                        | 2205.28               | 5.279                         | 1.00                             |
| 4                    | 2260                        | 2260.00               | $< 10^{-3}$                   | 1.00                             |
| 5                    | 2220                        | 2220.00               | $< 10^{-3}$                   | 1.00                             |
| 6                    | 2100                        | 2111.55               | 11.55                         | 1.01                             |
| 7                    | 900                         | 900.00                | $< 10^{-3}$                   | 1.00                             |
| 8                    | 856                         | 871.07                | 15.07                         | 1.02                             |
| 9                    | 900                         | 900.00                | $< 10^{-3}$                   | 1.00                             |
| 10                   | 858                         | 874.95                | 18.94                         | 1.02                             |
| 11                   | 405                         | 420.74                | 15.74                         | 1.04                             |
| 12                   | 755                         | 755.00                | $< 10^{-3}$                   | 1.00                             |
| 14                   | 1515                        | 1515.00               | $< 10^{-3}$                   | 1.00                             |
| 15                   | 910                         | 900.00                | 10.00                         | 1.01                             |
| 16                   | 850                         | 867.50                | 17.50                         | 1.02                             |
| 17                   | 761                         | 761.00                | $< 10^{-3}$                   | 1.00                             |
| 18                   | 844                         | 875.00                | 19.00                         | 1.02                             |
| 19                   | 412                         | 420.74                | 8.736                         | 1.02                             |
| 20                   | 750                         | 755.00                | 5.000                         | 1.01                             |
| avg.                 |                             |                       | 7.26                          | 1.01                             |
| max.                 |                             |                       | 19.00                         | 1.04                             |
| min.                 |                             |                       | $< 10^{-3}$                   | 1.00                             |

## 実験環境再現の一貫性の検証

前節までに 3D マーモセットモデル、3D キーポイント推定、3D 環境モデルの各要素を個別に評価した。本節では、これらの要素を統合したデジタルツイン環境の全体的な再現性を評価する。実際の撮影画像と、3D 環境上で推定姿勢に基づいてマーモセットを配置しレンダリングした画像を比較し、SSIM および PSNR を算出した。まず実験環境は 8 方向から撮影されているため、8 方向の環境カメラを Figure 7a 左、中央のように再現した。実際に撮影した動画のフレームを抽出すると個体が映り込む。そのため、推定された 3D キーポイントを用いて 3D マーモセットの姿勢も設定した。Figure 7a 左、中央に示すように実際のフレームと状況が対応するコンピュータで再現した画像を作成した。

それらの SSIM や PSNR を計算した出力結果の例を Figure 7a 右に示す。主に SSIM マップが表示されており、白い部分が SSIM スコアが 1 に近く構造的に類似している部分、黒い部分がスコアが 0 に近く類似していない部分を示す。この画像ペアの計算結果は、SSIM は 0.5962、PSNR は 18.48dB であった。Figure 7b には、8 台のカメラと 3 個体の全データからそれぞれ 100 フレームを抽出して算出した SSIM および PSNR の分布を示す。図の上段は PSNR、下段は SSIM であり、横軸には各カメラにおける値を BoxPlot で示した。各個体は左から A、B、C の順に配置している。全サンプルを通した平均値は、SSIM が約 0.588、PSNR が約 17.54 dB であった。これらの結果は、再現画像が実画像に対して一定の構造的類似性を保持している一方で、画素値レベルではなお明確な差異が残っていることを示している。すなわち、本再現画像は実画像の細部を完全に再現するものではないが、場面全体の構成や環境条件を近似的に反映していると解釈できる。この傾向は複数個体および複数カメラ視点にわたって共通して観察され、再現画像が実画像そのものの代替ではなく、環境条件の再現性を評価するためのデータとして有効であることを示している。

## Code Availability

2D・3D キーポイント推定パイプライン、3D 環境モデル寸法計測用 Python スクリプト、Blender 上での 3D 姿勢再現スクリプトは GitHub の 3D\_digital\_twin\_marmoset\_code リポジトリ ([https://github.com/c7h2y/3D\\_digital\\_twin\\_marmoset\\_code.git](https://github.com/c7h2y/3D_digital_twin_marmoset_code.git)) で公開されている。本文中に説明した、カメラキャリブレーションで使った OpenCV、3D キーポイント時空間平滑化に使用した anipose は GitHub リポジトリのコードで再利用されている。本研究では以下のソフトウェアを使用した。Blender v4.5.0 (表面モデル作成、リギング、環境モデル構築、レンダリング)、mmdetection v2.26.0 (Bounding Box 検出の学習)、mmpose v0.29.0 (HRNet-w48-DEKR 2D 姿勢推定の学習)、MATLAB R2023b (CT セグメンテーション前処理)、3D Slicer 4.11 および 3D Slicer プラグイン SlicerRT toolkit (Dice 係数・Hausdorff 距離の算出)。




Figure 7: 実験環境再現の一貫性の検証結果。(a),SSIM と PSNR を計算するときの例。左が実験環境でのマーマセットの写真, 中央が今回作成した 3D マーマセットのレンダリング画像、右が計算された SSIM マップ、画像上部に SSIM、PSNR スコアを示す。参考として、これらの画像の計算結果では SSIM は 0.5962、PSNR は 18.48dB であった。(b),a のような画像のペアを抽出して PSNR と SSIM を各画像 100 フレームで計算した結果を示す。上部が PSNR、下部が SSIM の BoxPlot 図。横軸は各カメラ、縦軸は PSNR,SSIM スコアを示す。左から個体 A、B、C の順で並んでいる。緑の破線は平均値、オレンジの実線は中央値を表す。

## Data Availability

The dataset is available from Zenodo at [DOI] and from an AWS S3 bucket at [URL]. The Zenodo archive contains representative files and metadata, whereas the full video dataset is hosted on AWS due to its size. All files are released under [license]. Checksums for the released files are provided in [filename].

## References

- [1] Cory T. Miller, Winrich A. Freiwald, David A. Leopold, Jude F. Mitchell, Afonso C. Silva, and Xiaoqin Wang. Marmosets: A Neuroscientific Model of Human Social Behavior. *Neuron*, 90(2):219–233, April 2016. doi:10.1016/j.neuron.2016.03.018
- [2] Hideyuki Okano. Current Status of and Perspectives on the Application of Marmosets in Neurobiology. *Annual Review of Neuroscience*, 44(Volume 44, 2021):27–48, July 2021. doi:10.1146/annurev-neuro-030520-101844
- [3] Claudia Perez-Cruz and Juan de Dios Rodriguez-Callejas. The common marmoset as a model of neurodegeneration. *Trends in Neurosciences*, 46(5):394–409, May 2023. doi:10.1016/j.tins.2023.02.002
- [4] Takaaki Kaneko, Jumpei Matsumoto, Wanyi Lu, Xincheng Zhao, Louie Richard Ueno-Nigh, Takao Oishi, Kei Kimura, Yukiko Otsuka, Andi Zheng, Kensuke Ikenaka, Kousuke Baba, Hideki Mochizuki, Hisao Nishijo, Ken-ichi Inoue, and Masahiko Takada. Deciphering social traits and pathophysiological conditions from natural behaviors in common marmosets. *Current Biology*, 34(13):2854–2867.e5, July 2024. doi:10.1016/j.cub.2024.05.033
- [5] Chaoqun Cheng, Zijian Huang, Ruiming Zhang, Guozheng Huang, Han Wang, Likai Tang, and Xiaoqin Wang. A real-time, multi-subject three-dimensional pose tracking system for the behavioral analysis of non-human primates. *Cell Reports Methods*, 5(2):100986, February 2025. doi:10.1016/j.crmeth.2025.100986
- [6] Alexander Woodward, Tsutomu Hashikawa, Masahide Maeda, Takaaki Kaneko, Keigo Hikishima, Atsushi Iriki, Hideyuki Okano, and Yoko Yamaguchi. The Brain/MINDS 3D digital marmoset brain atlas. *Scientific Data*, 5(1):180009, February 2018. doi:10.1038/sdata.2018.9
- [7] Terumi Yurimoto, Wakako Kumita, Kenya Sato, Rika Kikuchi, Gohei Oka, Yusuke Shibuki, Rino Hashimoto, Michiko Kamioka, Yumi Hayasegawa, Eiko Yamazaki, Yoko Kurotaki, Norio Goda, Junichi Kitakami, Tatsuya Fujita, Takashi Inoue, and Erika Sasaki. Development of a 3D tracking system for multiple marmosets under free-moving conditions. *Communications Biology*, 7(1):216, February 2024. doi:10.1038/s42003-024-05864-9

- [8] Luis A. Bolaños, Dongsheng Xiao, Nancy L. Ford, Jeff M. LeDue, Pankaj K. Gupta, Carlos Doebeli, Hao Hu, Helge Rhodin, and Timothy H. Murphy. A three-dimensional virtual mouse generates synthetic training data for behavioral analysis. *Nature Methods*, 18(4):378–381, April 2021. doi:10.1038/s41592-021-01103-9
- [9] Diego Aldarondo, Josh Merel, Jesse D. Marshall, Leonard Hasenclever, Ugne Klibaite, Amanda Gellis, Yuval Tassa, Greg Wayne, Matthew Botvinick, and Bence P. Ölveczky. A virtual rodent predicts the structure of neural activity across behaviours. *Nature*, 632(8025):594–602, August 2024. doi:10.1038/s41586-024-07633-4
- [10] Praneet C. Bala, Benjamin R. Eisenreich, Seng Bum Michael Yoo, Benjamin Y. Hayden, Hyun Soo Park, and Jan Zimmermann. Automated markerless pose estimation in freely moving macaques with Open-MonkeyStudio. *Nature Communications*, 11(1):4560, September 2020. doi:10.1038/s41467-020-18441-5
- [11] Aidan P. Murphy and David A. Leopold. A parameterized digital 3D model of the Rhesus macaque face for investigating the visual processing of social cues. *Journal of Neuroscience Methods*, 324:108309, August 2019. doi:10.1016/j.jneumeth.2019.06.001
- [12] Stefano Sandrone. Digital Twins in Neuroscience. *Journal of Neuroscience*, 44(31), July 2024. doi:10.1523/JNEUROSCI.0932-24.2024
- [13] Zheng Ge, Songtao Liu, Feng Wang, Zeming Li, and Jian Sun. YOLOX: Exceeding YOLO Series in 2021, August 2021. doi:10.48550/arXiv.2107.08430
- [14] Tsung-Yi Lin, Michael Maire, Serge Belongie, Lubomir Bourdev, Ross Girshick, James Hays, Pietro Perona, Deva Ramanan, C. Lawrence Zitnick, and Piotr Dollár. Microsoft COCO: Common Objects in Context, February 2015. doi:10.48550/arXiv.1405.0312
- [15] Zigang Geng, Ke Sun, Bin Xiao, Zhaoxiang Zhang, and Jingdong Wang. Bottom-Up Human Pose Estimation Via Disentangled Keypoint Regression. *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pages 14671–14681, 2021.
- [16] Pierre Karashchuk, Katie L. Rupp, Evyn S. Dickinson, Sarah Walling-Bell, Elischa Sanders, Eiman Azim, Bingni W. Brunton, and John C. Tuthill. Anipose: A toolkit for robust markerless 3D pose estimation. *Cell Reports*, 36(13):109730, September 2021. doi:10.1016/j.celrep.2021.109730
- [17] D. Troilo, H. C. Howland, and S. J. Judge. Visual optics and retinal cone topography in the common marmoset (*Callithrix jacchus*). *Vision Research*, 33(10):1301–1310, July 1993. doi:10.1016/0042-6989(93)90038-x



- [18] Csaba Pinter, Andras Lasso, An Wang, David Jaffray, and Gabor Fichtinger. SlicerRT: radiation therapy research toolkit for 3D Slicer. *Medical Physics*, 39(10):6332–6338, October 2012. doi:10.1118/1.4754659
- [19] Takaaki Kaneko and Jumpei Matsumoto. Training dataset for marmo3Dpose, related to the paper entitled "Deciphering social traits and pathophysiological conditions from natural behaviors in common marmosets", 2024. doi:10.5281/zenodo.11196013
- [20] Takaaki Kaneko and Jumpei Matsumoto. PrimatoModelling/marmo3Dpose: v0.2, 2024. doi:10.5281/zenodo.11207054

## Acknowledgements

We gratefully acknowledge the Central Institute for Experimental Medicine and Life Science and Dr. Takashi Inoue for providing the marmoset samples. We also thank MELTA Inc. for their support in the 3D modeling of the marmoset. This work was supported by JSPS KAKENHI under Grant Numbers JP22H05163 and JP24K03256 to K.N.; AMED under Grant Numbers JP22zf0127007, JP24wm0625414, and JP24wm0625404 to K.N.

## Author informations

### Authors and Affiliations

Graduate School of Engineering , University of Fukui, Japan  
Koki Iwata, Ken Nakae

National Institute for Physiological Sciences, National Institutes of Natural Sciences, Japan  
Takaaki Kaneko, Daisuke Koketsu, Atsushi Nambu

Institute of Biology, Leipzig University, Germany.  
Catia Correia Caeiro

Kyushu University, Japan  
Diego Thomas

Center for the Evolutionary Origins of Human Behavior, Kyoto University, Japan  
Takako Miyabe-Nishiwaki

Center for Brain Science, RIKEN, Japan  
Junichi Hata

## **Contributions**

K.I. was responsible for data curation, formal analysis, investigation, methodology, resources, software, validation, visualization, and writing – review & editing. T.K. was responsible for data curation, formal analysis, investigation, resources, and software. C.C.C. was responsible for data curation and resources. D.T. was responsible for formal analysis, methodology, and software. A.N. was responsible for data curation and resources. T.M.N. was responsible for data curation and resources. J.H. was responsible for data curation and resources. K.N. contributed to conceptualization, formal analysis, funding acquisition, investigation, methodology, project administration, resources, software, supervision, validation, and writing – review & editing.

## **Corresponding author**

Ken Nakae

## **Ethics declarations**

### **Competing interests**

The authors declare no competing interests.